



Tecnológico Nacional de México
Campus Querétaro

Ing. de datos.

Informe de proyecto

Que presenta:

**Alondra Itzel Castillo Ramírez
José Armando Martínez Pérez
Ma. Alejandrina Nieto Granados
Alondra Citlalli Razo Contreras
Adriana Scarlett Virgen Soto**

Estudiante de la carrera:

**Ing. en Gestión Empresarial.
Ing. en Sistemas Computacionales.**

Asesor:

Sandra Lucia de la Fuente Bermúdez

Periodo:

Enero - agosto 2026

Sistema Avanzado de Predicción NCAA 2026

1. Resumen Ejecutivo

El presente informe documenta el desarrollo, implementación y resultados de un modelo de aprendizaje automático de alto rendimiento diseñado para la competición **March Machine Learning Mania 2026**. El objetivo fundamental del proyecto es la predicción probabilística de los resultados del torneo de baloncesto de la NCAA, un desafío caracterizado por su alta volatilidad y la frecuencia de resultados inesperados ("upsets").

A diferencia de los enfoques de clasificación tradicionales que simplemente asignan un ganador, este sistema se centra en la **estimación de densidades de probabilidad**. Esto significa que el éxito del modelo no se mide solo por cuántos partidos acierta, sino por qué tan bien calibrada está su confianza ante la incertidumbre. El núcleo del proyecto reside en la premisa de que los datos históricos (que abarcan desde 1985 hasta 2025) contienen patrones latentes de rendimiento que, al ser procesados mediante técnicas de **Feature Engineering** y **Ensemble Learning**, pueden superar significativamente el juicio humano y los modelos estadísticos simples.

El sistema fue concebido bajo un marco de **rigor científico y escalabilidad**. Se abordaron problemas críticos como la fuga de datos (data leakage) y el sobreajuste (overfitting) mediante una arquitectura de validación temporal que simula las condiciones reales del torneo año tras año. Como resultado, se obtuvo un modelo que integra más de 60 sistemas de ranking diferentes, métricas de eficiencia avanzadas y algoritmos de boosting, logrando una herramienta capaz de generar predicciones robustas, minimizando la pérdida logarítmica (*Log Loss*) y maximizando la competitividad en entornos de alta exigencia.

2. Metodología de Modelado: Arquitectura de 10 Etapas

El desarrollo se estructuró en un pipeline riguroso diseñado para transformar datos crudos en probabilidades calibradas:

- **Etapas 1-3: Recolección y Consolidación de Datos:** Se integraron fuentes de datos que abarcan cuatro décadas. Esto incluye resultados de temporada regular, datos de los "seeds" del torneo y los **rankings de Massey**, que consolidan la opinión de expertos y algoritmos de todo Estados Unidos.
- **Etapas 4: Ingeniería de Características (Feature Engineering):**
 - **Sistemas de Calificación Elo:** Un método dinámico que actualiza la fuerza de un equipo tras cada partido, ajustado por la ventaja de localía y la calidad del oponente.

- **Diferenciales de Eficiencia:** Cálculos de puntos por posesión, integrando el ritmo de juego para normalizar el rendimiento ofensivo y defensivo.
- **Etapas 5-7: Selección de Algoritmos y Entrenamiento:** Se implementó una arquitectura de **Ensemble (Stacking)**.
- **Regresión Logística:** Proporciona estabilidad lineal.
- **XGBoost y LightGBM:** Modelos de Gradient Boosting que capturan interacciones complejas.
- **Etapas 8: Validación Temporal Cruzada:** Se utilizó una técnica de **Expanding Window**, donde el modelo se entrena con años anteriores y se prueba específicamente en las temporadas 2022-2025 de forma independiente.

3. Validación y Métricas de Desempeño

La evaluación del modelo se rige por la métrica de **Log Loss**.

- **Resultados de Validación:** El modelo demuestra una consistencia superior, manteniendo un Log Loss significativamente menor al baseline de 0.693. La calibración realizada permite que el modelo se comporte de manera conservadora ante enfrentamientos muy cerrados y sea agresivo solo cuando los datos coinciden firmemente.

4. Análisis de la Predicción Final y Dashboard

Mediante el **Dashboard de Ingeniería de Datos**, se validaron comportamientos clave:

- **Calibración Sigmoidal:** Las probabilidades finales fueron ajustadas para asegurar la fiabilidad estadística.
- **Límites de Seguridad:** Se aplicaron límites de confianza (CLIP_LOW: 0.025 y CLIP_HIGH: 0.975) para mitigar el impacto de las sorpresas extremas del torneo.

5. Conclusión

A. Solidez de la Arquitectura de Predicción.

La fortaleza de este modelo reside en su enfoque de **Ensemble (Stacking)**. Al no depender de un único algoritmo, el sistema logra equilibrar la capacidad de capturar relaciones lineales con la detección de patrones no lineales complejos. Esta redundancia algorítmica asegura que el modelo no colapse ante cambios en las tendencias de juego de una temporada a otra.

B. El Factor Elo como Diferenciador.

El análisis determinó que el **Sistema Elo** es la característica más determinante. Calibrado con un Factor K de 20 y una regresión a la media

de 0.6, este sistema proporciona una medida de la "memoria" del rendimiento del equipo, permitiendo al modelo entender quién llega en mejor forma al torneo de marzo.

C. Evaluación de Competitividad.

El modelo ha sido diseñado para ser altamente competitivo. Con un objetivo de Log Loss **menor a 0.55**, el sistema se posiciona dentro de los estándares de los mejores modelos a nivel mundial. La validación sobre las últimas cuatro temporadas garantiza que el modelo ha aprendido de la era moderna del baloncesto.

D. Reflexión Final.

En conclusión, el proyecto demuestra que la predicción del baloncesto universitario requiere tanto rigor estadístico como conocimiento del dominio. La combinación de **rankings Massey, sistemas Elo y algoritmos de boosting** genera una herramienta robusta que no solo predice quién ganará, sino que entiende la probabilidad real de cada resultado. El modelo representa la culminación de un proceso de ingeniería de datos exhaustivo, estando plenamente preparado para su ejecución en el torneo NCAA 2026.